Clasificación de uso de suelo en imágenes satelitales

EuroSAT

De una red densa a una CNN con aumento de datos

Lenin Caballero · Rafael Funez · Miguel Hernández
Aldo Rodríguez · Landon Treviño

Tecnológico de Monterrey, Campus Monterrey
22/10/2026

Problema y datos

EuroSAT RGB · Helber et al. (2019)

Clasificar automáticamente el uso y la cobertura del suelo en parches satelitales, una tarea lenta y costosa cuando se hace a mano.

27,000

imágenes RGB de Sentinel-2, 64 × 64 px

10

clases de terreno, de 2,000 a 3,000 imágenes cada una

70/15/15

entrenamiento, validación y prueba, estratificado

Partición con semilla 42: 18,900 imágenes de entrenamiento, 4,050 de validación y 4,050 de prueba.

Las dos redes

Adam, lr = 0.0001, lotes de 64, 20 épocas

MLP (línea base)

3,180,170 parámetros

Flatten: 12,288 valores
Dense 256 + ReLU + Dropout 0.5
Dense 128 + ReLU + Dropout 0.5
Dense 10 + softmax

No usa la vecindad entre píxeles.

CNN propia

1,337,898 parámetros

3 bloques: 2 × (Conv 3×3, BatchNorm, ReLU) + MaxPool
Filtros de 32, 64 y 128
Flatten (8,192) + Dense 128 + Dropout 0.5
Dense 10 + softmax

58 % menos parámetros que la MLP.

Curvas de la MLP

Curvas de aprendizaje

28 %

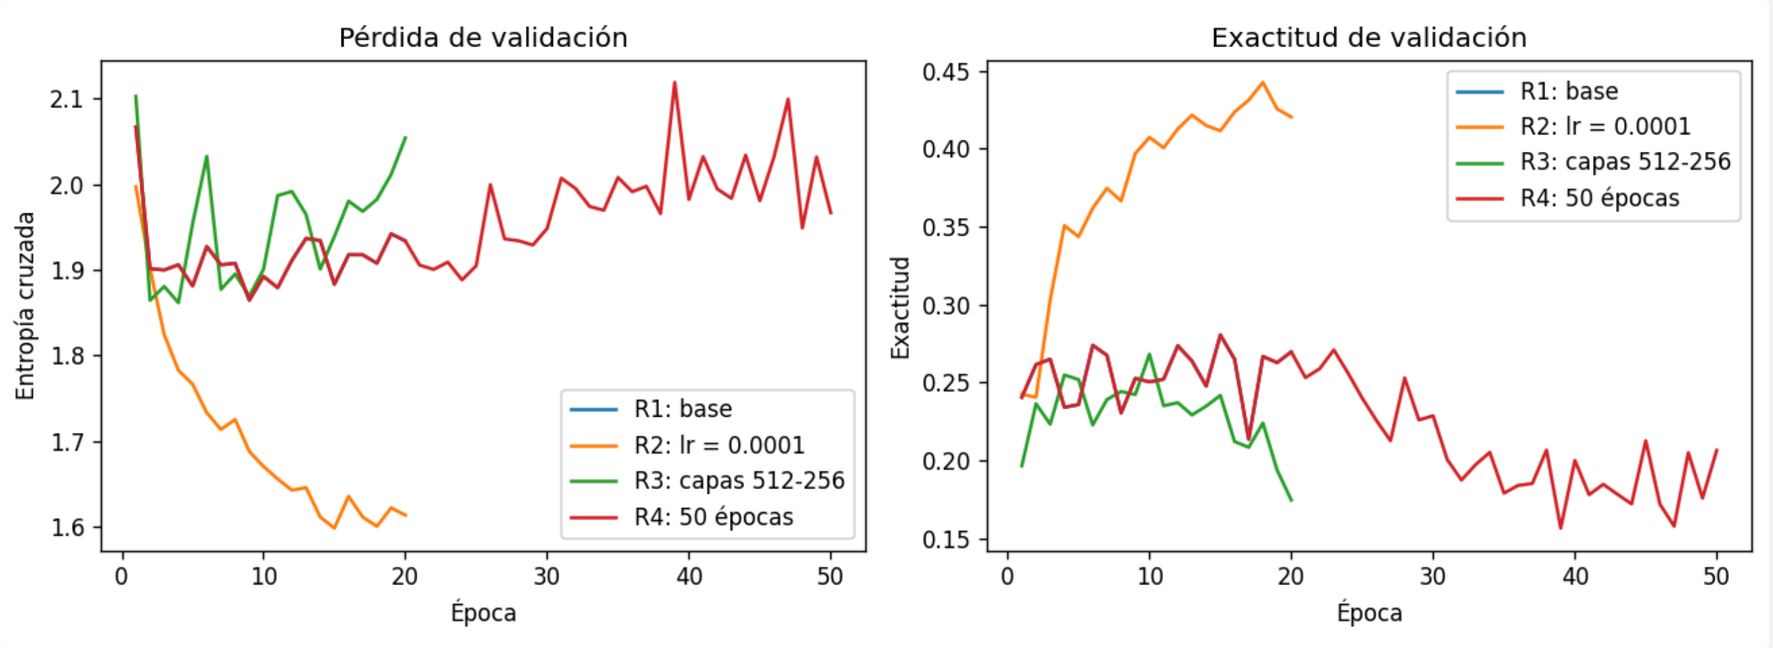
R1 (lr = 0.001), mejor exactitud de validación

44 %

R2 (lr = 0.0001), mejor exactitud de validación

17–21 %

R3 y R4, exactitud de validación al final

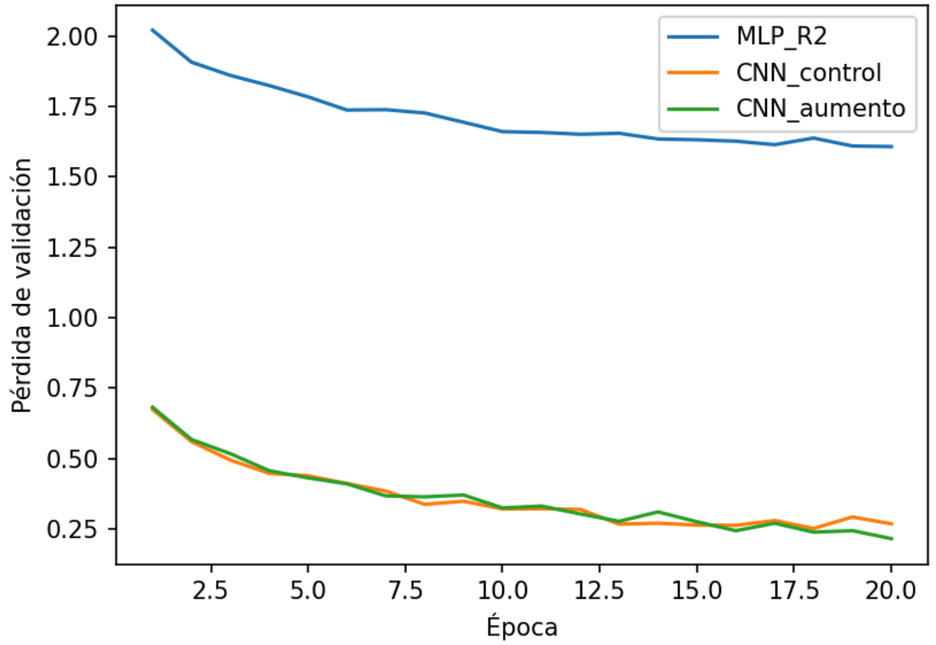


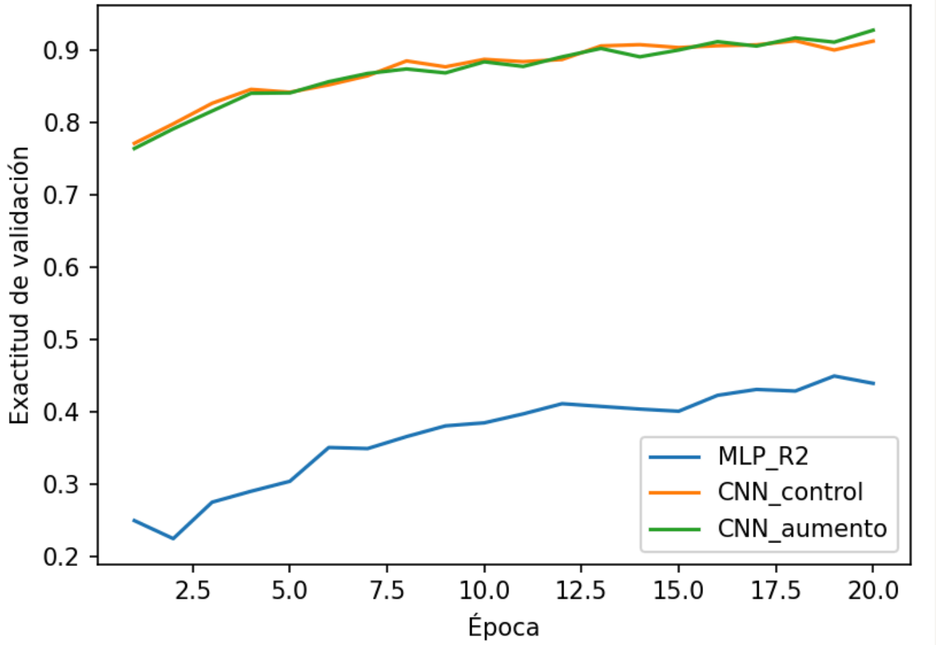
Pérdida y exactitud de validación de R1 a R4. R1 queda tapada por R4 (misma semilla).

Bajar la tasa de aprendizaje fue lo que más ayudó; más neuronas o más épocas no. Es subajuste y optimización, no sobreajuste.

MLP contra CNN

Curvas de aprendizaje





Pérdida y exactitud de validación, 20 épocas

44.96 %

MLP (R2), exactitud de validación

91.28 %

CNN sin aumento

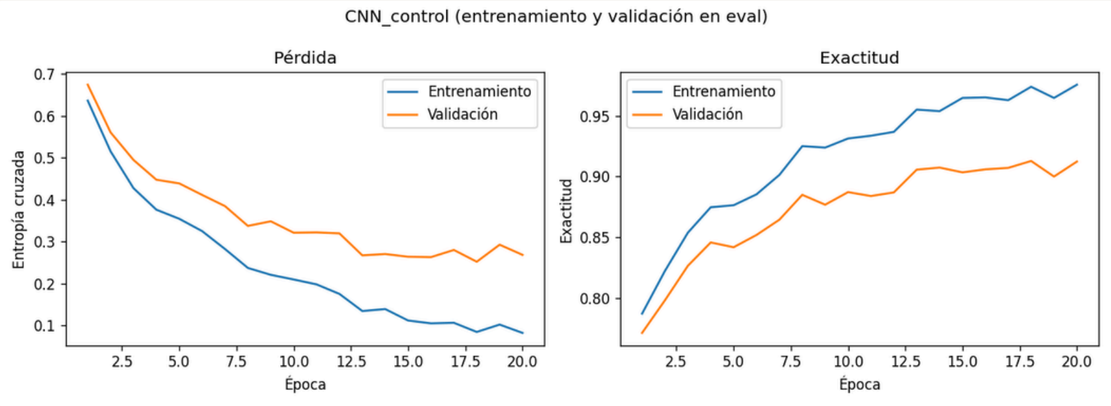
92.74 %

CNN con aumento

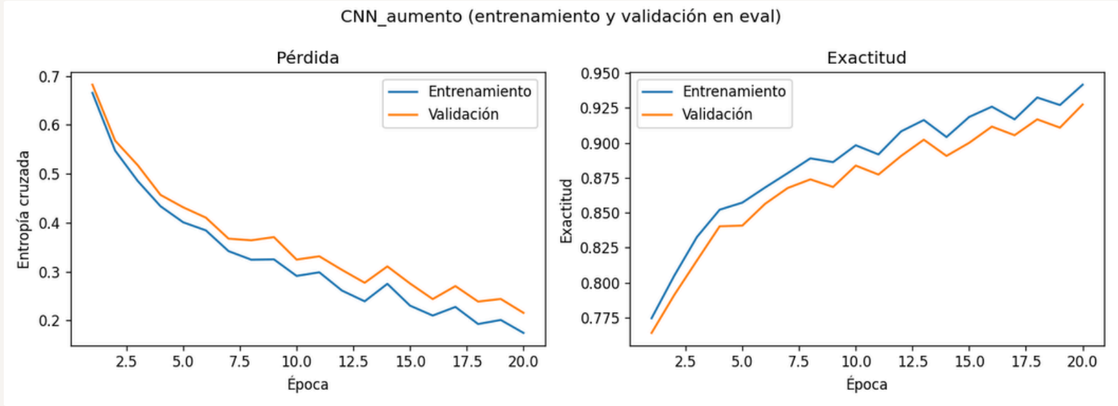
Elegimos con validación, antes de consultar prueba: la CNN con aumento tuvo la mayor exactitud y la menor pérdida.

Regularización

Dropout y aumento de datos



CNN de control · solo Dropout 0.5



CNN con aumento de datos

6.12 → 1.42 pp
brecha entre entrenamiento y validación

91.28 → 92.74 %
exactitud de validación

0.2518 → 0.2156
pérdida de validación

Menos señales de sobreajuste en esta partición, aunque no prueba que desaparezcan en otros escenarios.

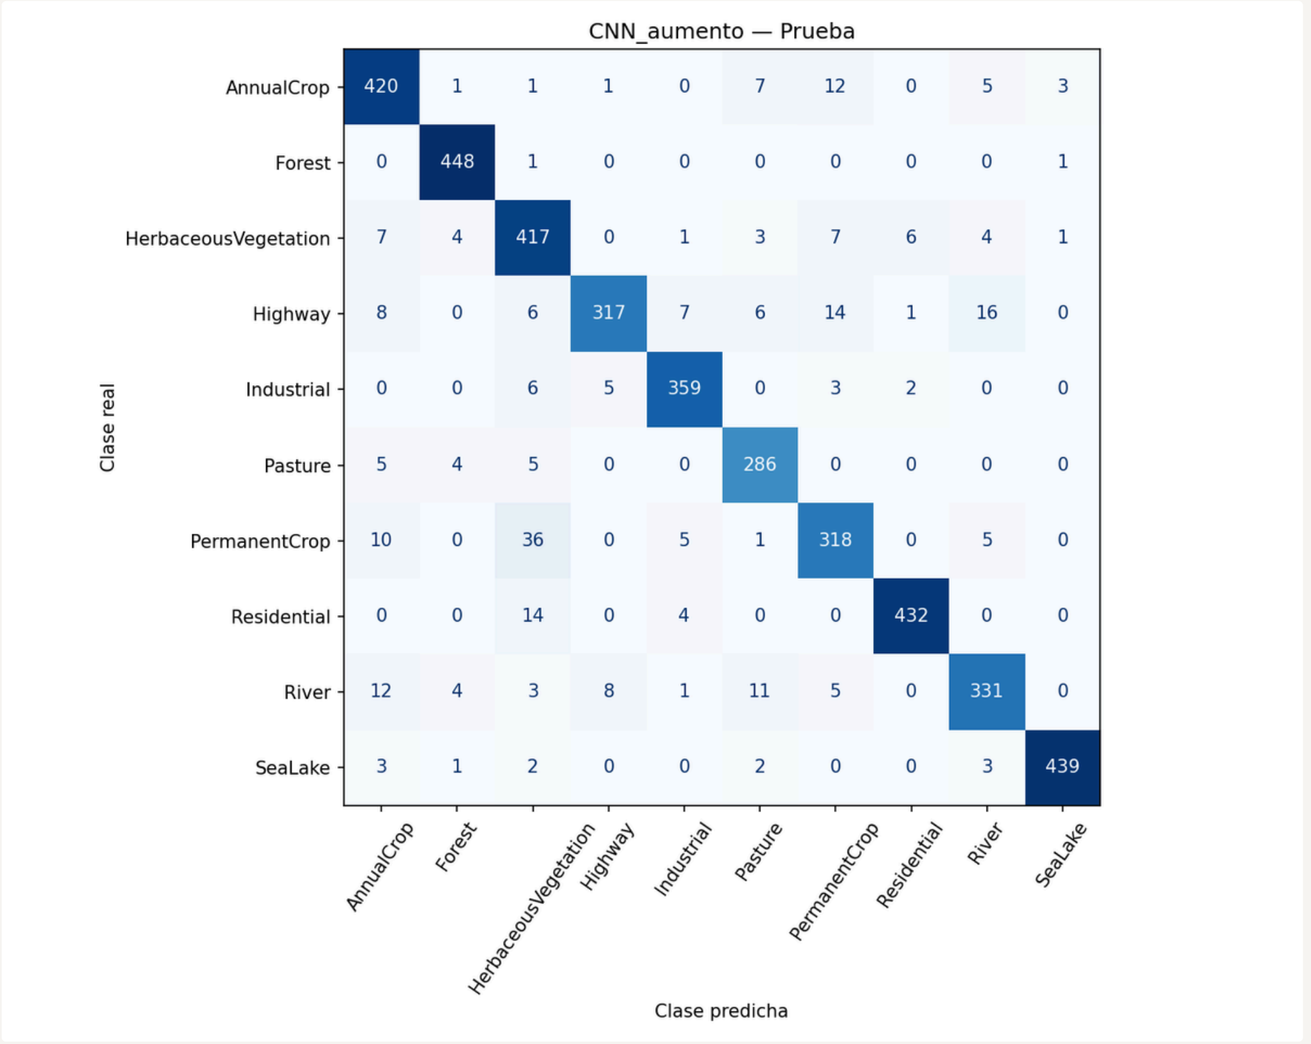
Resultados en prueba

4,050 imágenes · una sola consulta por modelo

93.01 %
CNN con aumento

45.19 %
MLP (R2)

F1 macro: 0.928 contra 0.418
Pérdida: 0.2055 contra 1.5999
Mejor clase: Forest (F1 0.983)
Más débil: PermanentCrop (F1 0.867)



Matriz de confusión de la CNN con aumento

Limitaciones

Del modelo y del enfoque

Una semilla, una partición
No medimos la variabilidad entre corridas; diferencias pequeñas como 1.46 pp pueden moverse.

Entrenamiento corto
La mejor época de la CNN fue la 20, la última: pudo faltar convergencia.

Comparación incompleta
La MLP no se probó con BatchNorm y ResNet-50 (98.57 % en Helber et al.) no se implementó.

Clases parecidas
Cultivo permanente se confunde con vegetación herbácea; carretera con río.

Clasificación por parche
No delimita parcelas ni edificios; un uso real requiere validación adicional.

Datos y aumento acotados
Solo Europa, 64 × 64 RGB; el aumento no crea observaciones independientes.

Conclusiones y reflexiones

Conclusiones

- La CNN con aumento llegó a 93.01 % en prueba, 47.83 pp sobre la MLP, con 58 % menos parámetros.
- La regularización redujo la brecha de 6.12 a 1.42 pp.
- La tasa de aprendizaje fue lo que más movió a la MLP.

Reflexiones

- Las curvas de aprendizaje distinguieron subajuste de sobreajuste: cada caso pide un remedio distinto.
- Proteger la prueba y elegir con validación hizo creíbles los resultados.

github.com/LeninCabCol/Reto-Redes-Neuronales-y-Aprendizaje-Profundo